KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

PHÂN TÍCH DỮ LIỆU BANK MARKETING

Các yếu tố liên quan đến đăng ký tiền gửi có kỳ hạn

BÁO CÁO DỰ ÁN TOPIC 2

Nhóm 2

Dữ liệu: Bank Marketing Dataset

Quy mô: 11.162 khách hàng, 17 biến

Repository mã nguồn: GitHub - Nhóm 2, Topic 2

Báo cáo được xây dựng từ notebook phân tích đã chạy và bộ dữ liệu bank.csv.

TÓM TẮT

Báo cáo phân tích bộ dữ liệu tiếp thị qua điện thoại của ngân hàng, với biến đích **deposit** cho biết khách hàng có đăng ký tiền gửi có kỳ hạn hay không. Tỷ lệ đăng ký trong dữ liệu là 47,38% (5.289/11.162). Phân tích kết hợp kiểm tra chất lượng dữ liệu, xử lý ngoại lệ, kiểm định mối liên hệ và xây dựng các mô hình phân loại.

Các kết quả mô tả cho thấy tỷ lệ đăng ký cao hơn ở nhóm từng có kết quả liên hệ thành công trước đó (91,32%; n=1.071), nhóm không có khoản vay nhà ở (57,03%; n=5.881), và khách hàng được liên hệ ít lần hơn trong chiến dịch hiện tại. Random Forest là mô hình tốt nhất trong các mô hình trước cuộc gọi theo ROC-AUC trên tập kiểm tra (0,786), nhưng vẫn cần đánh giá thêm trước khi triển khai. Mô hình có thêm biến duration đạt ROC-AUC 0,918, song biến này chỉ được biết sau cuộc gọi nên không phù hợp để sàng lọc khách hàng trước khi gọi.

Các phát hiện là mối liên hệ trong dữ liệu quan sát, không chứng minh quan hệ nhân quả. Đề xuất ứng dụng theo hướng xếp hạng ưu tiên để thử nghiệm có kiểm soát, đồng thời theo dõi hiệu quả và rủi ro vận hành.

1. BỐI CẢNH VÀ MỤC TIÊU

Tiếp thị qua điện thoại giúp ngân hàng giới thiệu sản phẩm tiền gửi có kỳ hạn đến khách hàng. Vì nguồn lực gọi điện hữu hạn, nhóm phân tích tập trung vào câu hỏi: những đặc điểm khách hàng và thông tin lịch sử liên hệ nào có liên quan đến việc đăng ký; và mô hình nào có thể hỗ trợ xếp hạng khách hàng trước khi thực hiện cuộc gọi?

Mục tiêu cụ thể: (i) mô tả cấu trúc, chất lượng bộ dữ liệu; (ii) làm sạch và chuẩn bị biến cho phân tích; (iii) kiểm định một số giả thuyết về mối liên hệ với kết quả đăng ký; (iv) so sánh các mô hình phân loại và đề xuất cách sử dụng thận trọng.

Nguồn dữ liệu được ghi trong notebook là Bank Marketing Dataset trên Kaggle. Repo nhóm công khai lưu notebook, dữ liệu và báo cáo: mở repository GitHub.

2. THU THẬP VÀ ĐÁNH GIÁ BAN ĐẦU

2.1. Quy mô, đơn vị quan sát và biến đích

Đặc điểm	Kết quả
Số quan sát	11.162 khách hàng / bản ghi chiến dịch
Số thuộc tính	17 cột: 16 biến giải thích và 1 biến đích
Biến đích	deposit: yes/no
Phân bố đích	yes = 5.289 (47,38%); no = 5.873 (52,62%)
Kiểu dữ liệu	7 biến số nguyên; 10 biến phân loại dạng chuỗi
Tệp đầu vào	bank.csv; một dòng biểu diễn một khách hàng trong dữ liệu chiến dịch

Các nhóm thuộc tính gồm thông tin cá nhân (age, job, marital, education), quan hệ tài chính (default, balance, housing, loan), thông tin liên hệ (contact, day, month, duration, campaign), lịch sử chiến dịch (pdays, previous, poutcome) và kết quả (deposit).

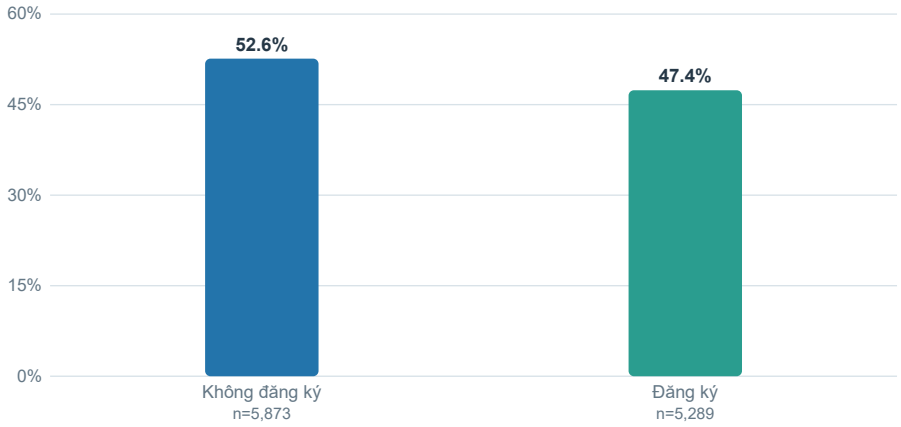
2.2. Chất lượng và tính nhất quán

Kiểm tra	Kết quả	Cách hiểu
Giá trị thiếu dạng null	0 ô	Không cần loại hoặc điền giá trị null.
Dòng trùng hoàn toàn	0 dòng	Không phát hiện bản ghi trùng theo toàn bộ cột.
Nhãn unknown	Có ở job, education, contact, poutcome	Đây là giá trị phân loại tường minh, không phải null; giữ như một mức riêng để tránh giả định thông tin không biết.
Miền giá trị	Các biến phân loại nằm trong nhóm nhãn kỳ vọng	Cần chú ý pdays=-1 biểu thị chưa được liên hệ trước đó trong dữ liệu.

Trong các nhãn unknown, poutcome có 8.326 quan sát (74,59%), contact có 2.346 (21,02%), education có 497 (4,45%) và job có 70 (0,63%). Do unknown ở poutcome thường biểu thị không có kết quả chiến dịch trước để ghi nhận, gộp nó vào một nhóm riêng giúp giữ đúng ý nghĩa dữ liệu.

Biểu đồ 1 cho thấy tập dữ liệu tương đối cân bằng giữa hai lớp. Tỷ lệ đăng ký 47,38% là tỷ lệ nền để đối chiếu các phân khúc và kết quả mô hình. Tỷ lệ này không đồng nghĩa xác suất thành công của một khách hàng cụ thể.

Phân bố biến đích deposit



Biểu đồ 1. Tỷ lệ và số lượng khách hàng theo kết quả đăng ký.

3. LÀM SẠCH VÀ TIỀN XỬ LÝ

3.1. Ngoại lệ và quy tắc xử lý

Nhóm dùng quy tắc IQR trên tập huấn luyện để xác định ngưỡng capping cho age, balance, duration và campaign. Các ngưỡng được ước lượng từ train rồi áp dụng nhất quán cho dữ liệu tương ứng; cách làm này hạn chế rò rỉ thông tin từ tập kiểm tra vào bước tiền xử lý. Capping giảm ảnh hưởng của giá trị cực đoan mà không xóa bản ghi.

Biến	Cận IQR dưới	Cận IQR trên	Lưu ý
age	6,5	74,5	Tuổi ngoại biên được giới hạn theo ngưỡng huấn luyện.
balance	-2.236	4.052	Số dư có thể âm; không xem âm là lỗi mặc định.
duration	-395,5	1.024,5	Dùng cho phân tích sau cuộc gọi; không đưa vào mô hình tiền cuộc gọi.
campaign	-2	6	Giới hạn số lần liên hệ trong chiến dịch hiện tại.

Các cận IQR là ngưỡng thống kê, không phải miền giá trị hợp lệ của nghiệp vụ. Riêng cận dưới âm của age/campaign không làm phát sinh giá trị âm nếu dữ liệu gốc vốn không có các giá trị đó.

3.2. Mã hóa, chia tập và tránh rò rỉ

Dữ liệu được chia train/test theo tỷ lệ 80/20 với random_state=42 và phân tầng theo deposit: train 8.929 quan sát, test 2.233 quan sát; tỷ lệ lớp được giữ ở khoảng 47,38%. Biến phân loại được one-hot encoding, biến số được chuẩn hóa bằng RobustScaler. Bộ biến đổi được fit trên train rồi áp dụng cho test.

Mô hình sàng lọc trước cuộc gọi không sử dụng duration. Thời lượng cuộc gọi chỉ được biết sau khi cuộc gọi diễn ra và có liên hệ rất mạnh với kết quả; đưa nó vào mô hình tiền cuộc gọi sẽ tạo rò rỉ thông tin. Notebook trình bày riêng mô hình có duration như một đối chiếu sau cuộc gọi, không dùng làm cơ sở chọn khách hàng trước khi gọi.

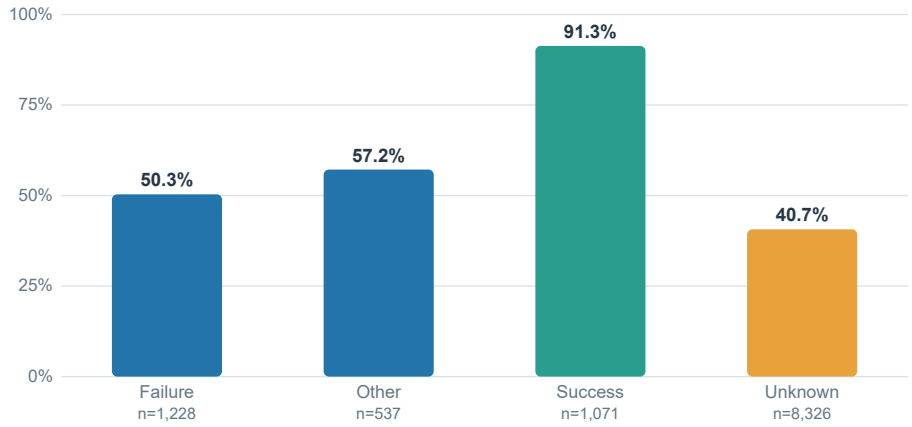
Các biến unknown được giữ như mức phân loại riêng. Notebook có xử lý capping cho age, balance, duration, campaign; previous có phân phối lệch phải mạnh (skewness khoảng 7,34) nhưng chưa được capping, nên cần xem đây là điểm cần đánh giá thêm, nhất là với các mô hình nhạy với thang đo.

4. PHÂN TÍCH KHÁM PHÁ VÀ KIỂM ĐỊNH

4.1. Tỷ lệ đăng ký theo kết quả liên hệ trước

Trong nhóm có poutcome=success, tỷ lệ deposit=yes là 91,32% (n=1.071), cao hơn rõ rệt tỷ lệ nền 47,38%. Nhóm poutcome=unknown có tỷ lệ 40,67% (n=8.326). Đây là tín hiệu phân khúc mạnh, nhưng kết quả trước đó có thể phản ánh cả mức độ quan tâm sẵn có và cách ngân hàng lựa chọn khách hàng trong các chiến dịch trước; không thể diễn giải là tác động nhân quả.

Tỷ lệ đăng ký theo kết quả chiến dịch trước

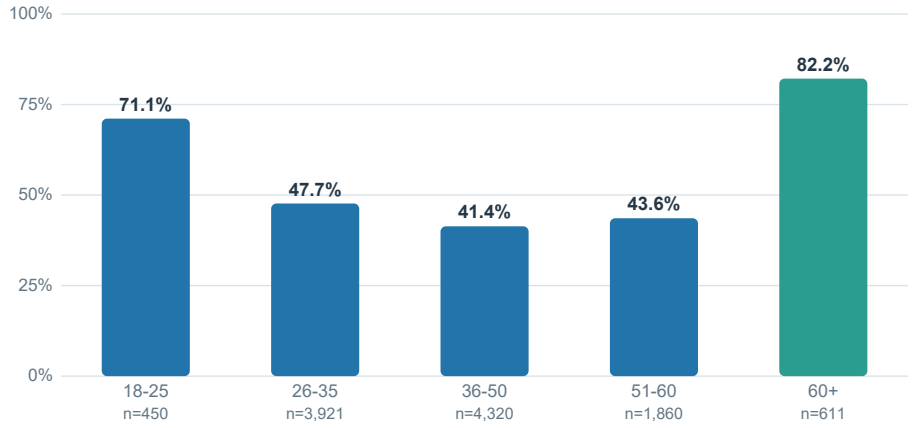


Biểu đồ 2. Tỷ lệ deposit=yes theo poutcome; nhãn n là số quan sát mỗi nhóm.

4.2. Khác biệt theo nhóm tuổi và số lần liên hệ

Tỷ lệ theo tuổi không tăng đều theo từng nhóm. Nhóm 60+ có tỷ lệ 82,16% nhưng chỉ có 611 quan sát; nhóm 18-25 đạt 71,11% với 450 quan sát. Hai nhóm này nhỏ hơn đáng kể so với các nhóm 26-35 (n=3.921) và 36-50 (n=4.320), vì vậy các tỷ lệ cao cần được xem cùng quy mô mẫu và xác nhận thêm trên dữ liệu mới.

Tỷ lệ đăng ký theo nhóm tuổi

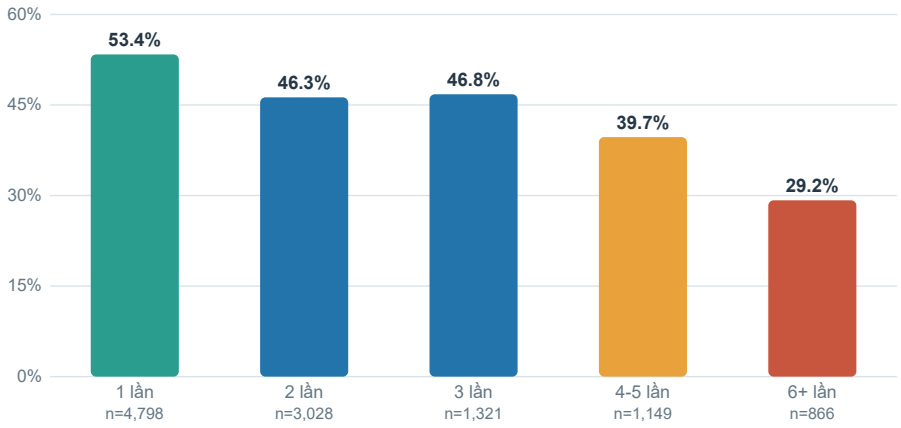


Biểu đồ 3. Tỷ lệ deposit=yes theo nhóm tuổi; tỷ lệ của nhóm nhỏ có độ bất định cao hơn.

4. PHÂN TÍCH KHÁM PHÁ VÀ KIỂM ĐỊNH (TIẾP)

Với số lần liên hệ trong chiến dịch hiện tại, tỷ lệ deposit=yes giảm ở các nhóm có nhiều lần gọi: nhóm 1 lần đạt 53,38% (n=4.798), nhóm 2 lần 46,27% (n=3.028), nhóm 3 lần 46,78% (n=1.321), nhóm 4-5 lần 39,69% (n=1.149), nhóm 6+ lần 29,21% (n=866). Đây là mối liên hệ mô tả; khách hàng khó tiếp cận có thể đồng thời nhận nhiều lần gọi, nên không kết luận rằng giảm số lần gọi tự nó sẽ làm tăng đăng ký.

Tỷ lệ đăng ký theo số lần gọi trong chiến dịch



Biểu đồ 4. Tỷ lệ deposit=yes theo số lần liên hệ; nhóm 6+ có tỷ lệ thấp nhất trong các nhóm hiển thị.

Một số khác biệt khác: khách hàng không có khoản vay nhà ở có tỷ lệ đăng ký 57,03% (n=5.881), so với 36,64% ở nhóm có khoản vay (n=5.281). Khách hàng không có khoản vay cá nhân có tỷ lệ 49,53% (n=9.702), so với 33,15% ở nhóm có khoản vay (n=1.460). Theo balance quartile, tỷ lệ tăng từ Q1 35,96% lên Q4 57,49%; đây là phân nhóm theo dữ liệu, không khẳng định số dư gây ra quyết định đăng ký.

4.3. Kiểm định giả thuyết

Các kiểm định so sánh tỷ lệ/ phân phối kết quả giữa các nhóm được hiệu chỉnh đa kiểm định bằng phương pháp Holm. Mức ý nghĩa sử dụng là 5%. Với kiểm định Mann-Whitney một phía cho balance, giả thuyết hướng là nhóm đăng ký có balance cao hơn; các kiểm định còn lại đánh giá sự khác biệt về deposit giữa các nhóm.

Giả thuyết / biến nhóm	Phương pháp	Thống kê	Kết luận sau Holm
Balance theo deposit	Mann-Whitney U, một phía	Theo notebook	Có bằng chứng balance nhóm yes cao hơn; p hiệu chỉnh < 0,05
Nhóm tuổi	Chi-square, df=4	χ^2=471,56	Phân phối deposit khác nhau; p hiệu chỉnh < 0,05
Nhóm campaign	Chi-square, df=4	χ^2=212,78	Tỷ lệ khác nhau giữa nhóm số lần gọi; p hiệu chỉnh < 0,05
Housing loan	Chi-square, df=1	χ^2=463,19	Tỷ lệ khác nhau theo housing; p hiệu chỉnh < 0,05
Personal loan	Chi-square, df=1	χ^2=135,83	Tỷ lệ khác nhau theo loan; p hiệu chỉnh < 0,05
Poutcome	Chi-square, df=3	χ^2=1.004,64	Tỷ lệ khác nhau theo kết quả trước; p hiệu chỉnh < 0,05
Month	Chi-square, df=11	χ^2=1.046,77	Tỷ lệ khác nhau theo tháng; p hiệu chỉnh < 0,05

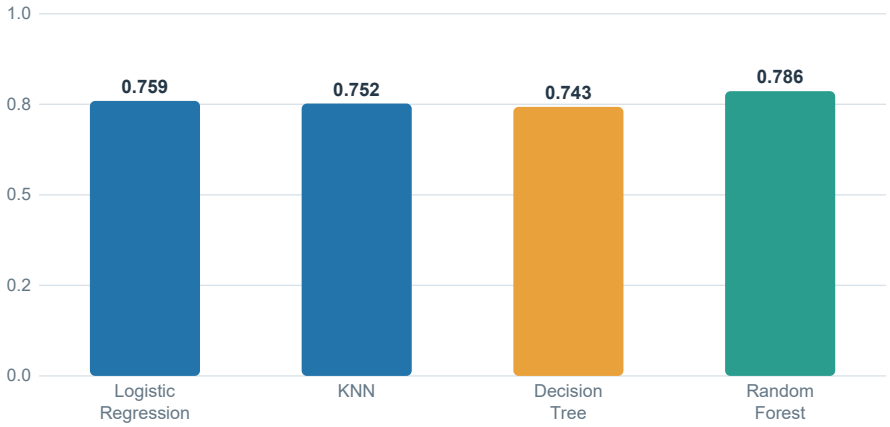
Các kiểm định cho thấy có bằng chứng về khác biệt thống kê trong mẫu. Giá trị p không đo độ lớn tác động hay giá trị kinh doanh; với cỡ mẫu lớn, khác biệt nhỏ cũng có thể có ý nghĩa. Vì vậy cần đọc cùng tỷ lệ, quy mô mẫu, mục đích chiến dịch và khả năng khái quát sang thời điểm khác.

Theo tháng, trong các tháng có ít nhất 500 quan sát, April có tỷ lệ đăng ký 62,51%, May 32,75%. Kiểm định tổng thể theo month có ý nghĩa sau hiệu chỉnh, nhưng mức chênh theo tháng có thể chịu ảnh hưởng mùa vụ và cơ cấu chiến dịch.

5. MÔ HÌNH HÓA VÀ ĐÁNH GIÁ

Bốn mô hình được so sánh trên cùng phép chia train/test: Logistic Regression, K-Nearest Neighbors (KNN), Decision Tree và Random Forest. Bài toán có hai lớp với tỷ lệ khá cân bằng; ROC-AUC được dùng để đo khả năng xếp hạng, đồng thời báo cáo accuracy để dễ diễn giải. Các chỉ số trên test phản ánh một lần chia dữ liệu, chưa phải ước lượng ổn định qua nhiều lần xác nhận.

ROC-AUC trên tập test: mô hình tiền cuộc gọi



Biểu đồ 5. ROC-AUC của mô hình tiền cuộc gọi trên test; Random Forest đạt giá trị cao nhất trong lần chia này.

Mô hình	Accuracy test	ROC-AUC test	Ghi chú
Logistic Regression	0,7022	0,7594	Mô hình tuyến tính, dễ diễn giải tương đối.
KNN	0,7049	0,7521	Phụ thuộc khoảng cách và chuẩn hóa.
Decision Tree	0,6928	0,7430	Có thể nắm quan hệ phi tuyến nhưng dễ biến động.
Random Forest	0,7318	0,7863	Tốt nhất trong bốn mô hình theo ROC-AUC test.

Random Forest có accuracy train 0,8029 và accuracy test 0,7318, chênh lệch 0,0711. Khoảng cách này gợi ý overfitting ở mức cần lưu ý. Siêu tham số được đặt cố định và kết quả dựa trên một lần chia train/test; chưa có cross-validation hay tìm kiếm siêu tham số nên không nên xem thứ hạng là kết luận cuối cùng.

Đối chiếu rò rỉ thông tin: khi thêm duration, ROC-AUC tăng lên 0,9075 (Logistic Regression), 0,8960 (KNN), 0,8816 (Decision Tree) và 0,9182 (Random Forest). Mức tăng lớn phù hợp với việc duration chứa thông tin chỉ phát sinh trong cuộc gọi. Các kết quả này chỉ có thể tham khảo cho phân tích sau cuộc gọi, không được dùng để dự báo trước cuộc gọi.

6. KẾT LUẬN VÀ ĐỀ XUẤT ỨNG DỤNG

Trong bộ dữ liệu, lịch sử chiến dịch trước, số lần gọi hiện tại, một số đặc điểm tài chính và tuổi có mối liên hệ với kết quả đăng ký. Random Forest cho khả năng xếp hạng tốt nhất trong các mô hình tiền cuộc gọi đã thử, nhưng ROC-AUC 0,786 và chênh lệch train-test cho thấy kết quả còn cần kiểm chứng.

Đề xuất: sử dụng điểm mô hình như một tín hiệu hỗ trợ phân bổ thứ tự liên hệ, không tự động loại khách hàng khỏi chiến dịch. Trước khi áp dụng rộng, ngân hàng nên thử nghiệm ngẫu nhiên có nhóm đối chứng trên một giai đoạn vận hành do đơn vị quyết định; so sánh tỷ lệ đăng ký, chi phí mỗi đăng ký, tỷ lệ từ chối liên hệ, khiếu nại và mức độ công bằng giữa các nhóm. Cần đặt giới hạn số lần gọi và quy tắc liên hệ theo chính sách hiện hành, sau đó cập nhật mô hình khi có dữ liệu mới.

Dữ liệu hiện có không có chi phí cuộc gọi, doanh thu/lợi nhuận tiền gửi hay giá trị vòng đời khách hàng. Do đó, báo cáo chưa thể kết luận mô hình làm tăng lợi nhuận hoặc tối ưu ROI; các con số mục tiêu kinh doanh cần được xác lập từ baseline và nguồn lực thực tế trước khi thử nghiệm.

7. HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

Hạn chế	Ảnh hưởng	Hướng xử lý tiếp
Dữ liệu quan sát, một nguồn và một giai đoạn	Có thể có thiên lệch chọn mẫu; mối liên hệ không hàm ý nhân quả.	Kiểm định trên chiến dịch/thời điểm khác và thử nghiệm có đối chứng.
Một lần chia train/test, seed cố định	Kết quả có thể thay đổi theo cách chia.	Dùng cross-validation phân tầng, lặp nhiều seed và báo cáo khoảng biến thiên.
Siêu tham số đặt cố định	Chưa chắc đã đạt cấu hình phù hợp cho từng mô hình.	Tìm siêu tham số trong cross-validation, chỉ chọn theo train/validation.
Random Forest có gap accuracy 0,0711	Có dấu hiệu overfitting; hiệu quả ngoài mẫu có thể thấp hơn.	Điều chỉnh độ sâu/số lá, kiểm tra calibration và xác nhận ngoài mẫu.
previous lệch phải mạnh, skewness≈7,34	Một số mô hình nhạy với phân phối lệch có thể kém ổn định.	So sánh biến đổi log1p/nhóm hóa với pipeline hiện tại trong validation.
Không có dữ liệu chi phí và giá trị khách hàng	Không đánh giá ROI hoặc lợi nhuận tăng thêm.	Bổ sung chi phí liên hệ, biên lợi nhuận và kết quả vận hành.
Nhãn unknown tập trung ở một số biến	Có thể phản ánh cách thu thập/ghi nhận, không phải thiếu ngẫu nhiên.	Làm rõ từ điển dữ liệu và theo dõi tác động của từng nhóm unknown.

8. TÁI LẬP VÀ QUẢN LÝ MÃ NGUỒN

Notebook phân tích được lưu ở định dạng .ipynb và đã chạy lại từ đầu đến cuối trên Google Colab, có output trong các ô. Mã được tổ chức theo các khối: nạp dữ liệu, kiểm tra chất lượng, khám phá, tiền xử lý, kiểm định, mô hình hóa và khuyến nghị. Bộ dữ liệu CSV và notebook được lưu cùng repository công khai của nhóm.

Repository GitHub:
https://github.com/hlinhhochoc/Nh-m-2---Topic-2---L-p-Logistics-v-QLCCU-CLC-66B---TOKT1138-126-CLC_57

Các hình trong báo cáo được dựng từ những tỷ lệ và kết quả thể hiện trong notebook; notebook cũng lưu biểu đồ dưới dạng output của các ô chạy. Khi cập nhật phân tích, cần chạy lại toàn bộ notebook và lưu phiên bản .ipynb có output lên repository để người đọc có thể kiểm tra quy trình.

TÀI LIỆU VÀ NGUỒN

1. Bank Marketing Dataset, Kaggle: https://www.kaggle.com/datasets/janiobachmann/bank-marketing-dataset.

2. Notebook phân tích và dữ liệu của Nhóm 2: repository GitHub nêu tại mục 8.

3. Đề bài Mid-term 2, học phần Khoa học dữ liệu trong kinh tế và kinh doanh: yêu cầu báo cáo theo các giai đoạn thu thập/đánh giá, làm sạch, phân tích/kiểm định và kết luận/ứng dụng; yêu cầu quản lý notebook và báo cáo trên GitHub.

Kết thúc báo cáo